



ОНЛАЙН-ОБРАЗОВАНИЕ

# Онлайн-образование



Проверить, идет ли запись!







# Меня хорошо видно && слышно?

Ставьте ☐ , если все хорошо  
Напишите в чат, если есть проблемы



# Матричные разложения. SVD



Легкоступ Виктор Валерьевич

Научный сотрудник  
ОАО «АЛЕВКУРП»



# Преподаватель



## Легкоступ Виктор

- 5 лет работы научным сотрудником на предприятии, осуществляющим проектирование БЛА.
- Специализация: фильтрация данных, оценивание параметров систем, системы автоматического управления, обработка сигналов, численные методы, аэродинамика, параллельные вычисления.
- Базовые инструменты: Matlab/Simulink, Mathematica, Python, C++
- Профессиональные интересы: БЛА, системы управления и измерения, моделирование на C++, Python, Matlab

# Правила вебинара



Активно участвуем



Задаем вопрос в чат или голосом



Off-topic обсуждаем в Slack #канал группы или #general



Вопросы вижу в чате, могу ответить не сразу

# Маршрут вебинара

Матричные разложения.  
SVD



Рекомендации



ALS



Практика в Python

# Цели вебинара | После занятия вы сможете

1

Рассказать, что такое SVD, его область применения, описать основные свойства

2

Рассказать смысл матричного приближения, ALS

3

Увидеть, как применить SVD в некоторых задачах



# СМЫСЛ | Зачем вам это уметь

1

Разработка рекомендательных систем

2

Получение пространства признаков,  
снижение размерности данных

3

Так или иначе, но SVD выходит далеко за рамки Data Science.  
Большая часть всех разложений сводится к SVD.  
SVD находит применение в:  
методе наименьших квадратов, методе главных компонент,  
сжатии данных, получении псевдообратных матриц и т.д.



The image features a high-angle, aerial view of a dense urban skyline, likely New York City, with numerous skyscrapers and buildings. The entire image is overlaid with a semi-transparent blue and green gradient. A network of thin, light blue lines connects various points across the image, creating a digital or technological feel. The word "Начало" is centered in the middle of the image in a white, sans-serif font.

Начало



# Матричные разложения

Матричное разложение (англ. factorization/decomposition) – представление матрицы в виде произведения других более простых матриц (обычно это 2 или 3 матрицы), обладающих особенными или полезными свойствами.

Виды:

- SVD
- QR
- LU
- Cholesky
- и другие


# Singular Value Decomposition (SVD)

Чем оно полезно?

- 1) Выделение существенных характеристик данных
- 2) Снижение размерности данных (сжатие)
- 3) Фильтрация
- 4) Предсказание неизвестных данных



# Разложение вектора на произведение векторов



# Разложение матрицы на произведение матриц. SVD

$$X = U \Sigma V^T$$

$U$  – ортогональная матрица левых собственных векторов  $XX^T$   
 $V$  – ортогональная матрица правых собственных векторов  $X^T X$   
 $\Sigma$  – диагональная матрица сингулярных чисел  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$   
являющихся корнями из собственных чисел матрицы  $XX^T$


$$U^T U = I$$

$$V^T V = I$$

$$\begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & \\ \vdots & \vdots & \ddots & \\ x_{m1} & & & x_{mn} \end{pmatrix}_{m \times n} = \begin{pmatrix} u_{11} & \dots & u_{1r} \\ \vdots & \ddots & \\ u_{m1} & & u_{mr} \end{pmatrix}_{m \times r} \begin{pmatrix} \sigma_{11} & 0 & \dots \\ 0 & \ddots & \\ \vdots & & \sigma_{rr} \end{pmatrix}_{r \times r} \begin{pmatrix} v_{11} & \dots & v_{1n} \\ \vdots & \ddots & \\ v_{r1} & & v_{rn} \end{pmatrix}_{r \times n}$$



# SVD



- Столбцы матрицы  $U$  – собственные векторы  $XX^T$
- Столбцы матрицы  $V$  – собственные векторы  $X^T X$
- На диагонали матрицы  $S$  находятся сингулярные числа – корни из собственных значений матрицы  $XX^T$  или  $X^T X$

# Усечённое SVD. Низкоранговое приближение.

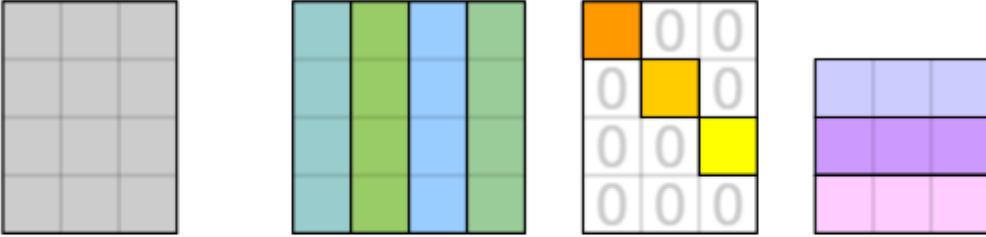
- Приближаем матрицу  $A$  матрицей меньшего ранга  $r$ , учитывая то, что за **основную** часть информации матрицы  $A$  отвечают **первые** сингулярные числа.
- Таким образом получается сохранить наибольшую часть информации, задействовав **меньше памяти**. При этом отброшенные сингулярные числа считаем «шумовыми».
- Это является аналогом **низкочастотной фильтрации** данных.


The diagram illustrates the truncated SVD decomposition of matrix  $A$ . Matrix  $A$  (size  $n \times d$ ) is shown as a single pink block. It is equal to the product of three matrices:  $\hat{U}$  (size  $n \times r$ , pink),  $\hat{\Sigma}$  (size  $r \times r$ , pink), and  $\hat{V}^T$  (size  $r \times d$ , pink). The matrices  $U$  (size  $n \times n$ ),  $\Sigma$  (size  $n \times d$ ), and  $V^T$  (size  $d \times d$ ) are shown as blue blocks. The pink blocks represent the truncated versions of these matrices, where only the first  $r$  columns of  $U$ , the first  $r$  rows of  $\Sigma$ , and the first  $r$  rows of  $V^T$  are retained.

$$\begin{matrix} \boxed{\begin{matrix} A \\ n \times d \end{matrix}} = \boxed{\begin{matrix} \hat{U} \\ n \times r \end{matrix}} \boxed{\begin{matrix} \hat{\Sigma} \\ r \times r \end{matrix}} \boxed{\begin{matrix} \hat{V}^T \\ r \times d \end{matrix}} \\ \begin{matrix} U \\ n \times n \end{matrix} \quad \begin{matrix} \Sigma \\ n \times d \end{matrix} \quad \begin{matrix} V^T \\ d \times d \end{matrix} \end{matrix}$$



# Памятка о виде матриц в SVD


$$\begin{matrix} \mathbf{M} \\ m \times n \end{matrix} = \begin{matrix} \mathbf{U} \\ m \times m \end{matrix} \begin{matrix} \mathbf{\Sigma} \\ m \times n \end{matrix} \begin{matrix} \mathbf{V}^* \\ n \times n \end{matrix}$$


$$\begin{matrix} \mathbf{U} \\ 4 \times 4 \end{matrix} \begin{matrix} \mathbf{U}^* \\ 4 \times 4 \end{matrix} = \mathbf{I}_4$$
$$\begin{matrix} \mathbf{V} \\ 3 \times 3 \end{matrix} \begin{matrix} \mathbf{V}^* \\ 3 \times 3 \end{matrix} = \mathbf{I}_3$$

# Пример SVD разложения матрицы

$$AA^T = \begin{pmatrix} 17 & 8 \\ 8 & 17 \end{pmatrix}$$

$$\sigma_1 = \sqrt{25} = 5 \quad \sigma_2 = \sqrt{9} = 3$$

eigenvalues:  $\lambda_1 = 25, \lambda_2 = 9$

eigenvectors

$$u_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} \quad u_2 = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

$$A = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$$

$$A^T A = \begin{pmatrix} 13 & 12 & 2 \\ 12 & 13 & -2 \\ 2 & -2 & 8 \end{pmatrix}$$


eigenvalues:  $\lambda_1 = 25, \lambda_2 = 9, \lambda_3 = 0$

eigenvectors

$$v_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \\ 0 \end{pmatrix} \quad v_2 = \begin{pmatrix} 1/\sqrt{18} \\ -1/\sqrt{18} \\ 4/\sqrt{18} \end{pmatrix} \quad v_3 = \begin{pmatrix} 2/3 \\ -2/3 \\ -1/3 \end{pmatrix}$$

$$A = USV^T = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 5 & 0 & 0 \\ 0 & 3 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 1/\sqrt{18} & -1/\sqrt{18} & 4/\sqrt{18} \\ 2/3 & -2/3 & -1/3 \end{pmatrix}$$

# Геометрический смысл SVD





# Связь SVD с Методом Главных Компонент (PCA)

Необходимо диагонализировать ковариационную матрицу

$$C = \frac{X^T X}{n-1}$$

где  $X$  – центрированная матрица исследуемых данных

Представим ковариационную матрицу через SVD:

$$C = \frac{V \Sigma U^T U \Sigma V^T}{n-1} = V \frac{\Sigma^2}{n-1} V^T$$

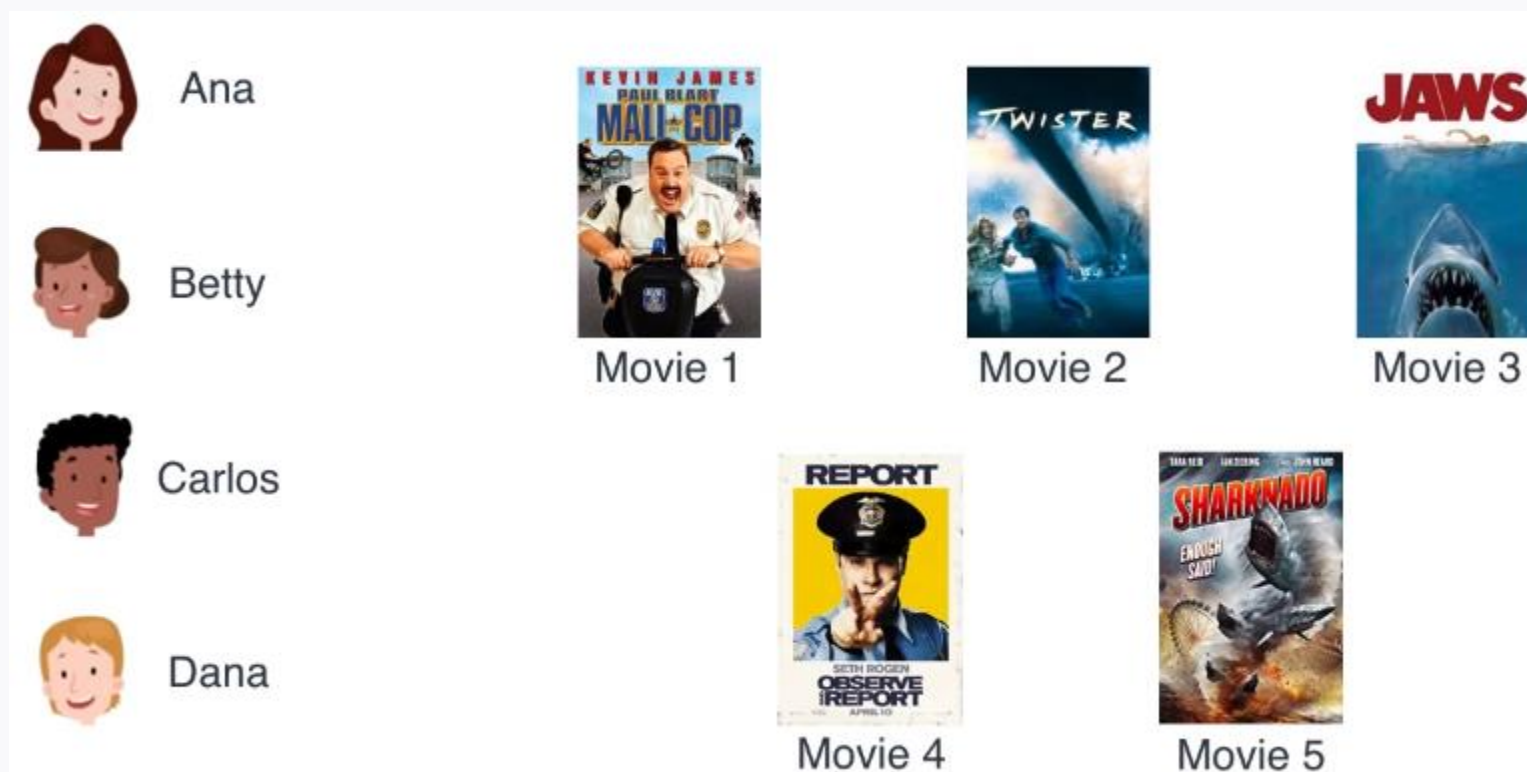
$$\lambda_i = \frac{\sigma_i^2}{n-1} \quad - \text{собственные значения матрицы } X^T X$$

Столбцы матрицы  $U$  соответствуют собственным векторам матрицы  $X^T X$

Это считается быстрее, чем вычисление ковариационной матрицы в лоб с последующим получением собственных векторов





# Как применить SVD для рекомендации фильмов

Четыре пользователя оценили пять фильмов




Кластеризация пользователей и фильмов

# Как применить SVD для рекомендации фильмов





	M 1	M 2	M 3	M 4	M 5
	3	1	1	3	1
	1	2	4	1	3
	3	1	1	3	1
	4	3	5	4	4

	M1	M2	M3	M4	M5
	3	1	1	3	1
					
	3	1	1	3	1
					





# Как применить SVD для рекомендации фильмов

	M1	M2	M3	M4	M5
	3	1	1	3	1
	1	2	4	1	3
	3	1	1	3	1
	4	3	5	4	4

	1	2	4	1	3
	3	1	1	3	1
	4	3	5	4	4

$$\begin{array}{c} \text{User B} \\ \text{B} \end{array} + \begin{array}{c} \text{User C} \\ \text{C} \end{array} = \begin{array}{c} \text{User D} \\ \text{D} \end{array}$$

# Как применить SVD для рекомендации фильмов

	M1	M2	M3	M4	M5
User 1	3	1	1	3	1
User 2	1	2	4	1	3
User 3	3	1	1	3	1
User 4	4	3	5	4	4


	M1	M2	M3	M4	M5
User 1	3			3	
User 2	1			1	
User 3	3			3	
User 4	4			4	

	M1	M2	M3	M4	M5
User 1		1	1		1
User 2		2	4		3
User 3		1	1		1
User 4		3	5		4

$$M1 = M4$$







$$M5 = \text{Average}(M2, M3)$$



# Как применить SVD для рекомендации фильмов

Что, если некоторых оценок нет и мы хотим их спрогнозировать?

**Вопрос:** на основании чего мы можем это сделать?


	M1	M2	M3	M4	M5
	3	3	3	3	3
	3	3	3	3	3
	3	3	3	?	3
	3	3	3	3	3

	M1	M2	M3	M4	M5
	3	1	1	3	1
	1	2	4	1	3
	3	1	1	3	
	4	3	5	4	4



# Как применить SVD для рекомендации фильмов

Что, если некоторых оценок нет и мы хотим их спрогнозировать?




# Как применить SVD для рекомендации фильмов

Вместо того, чтобы хранить информацию в изначальном виде с «закодированными признаками», мы можем попытаться выделить некоторое пространство признаков, осуществляющие связь между пространствами пользователей и фильмов

## Features

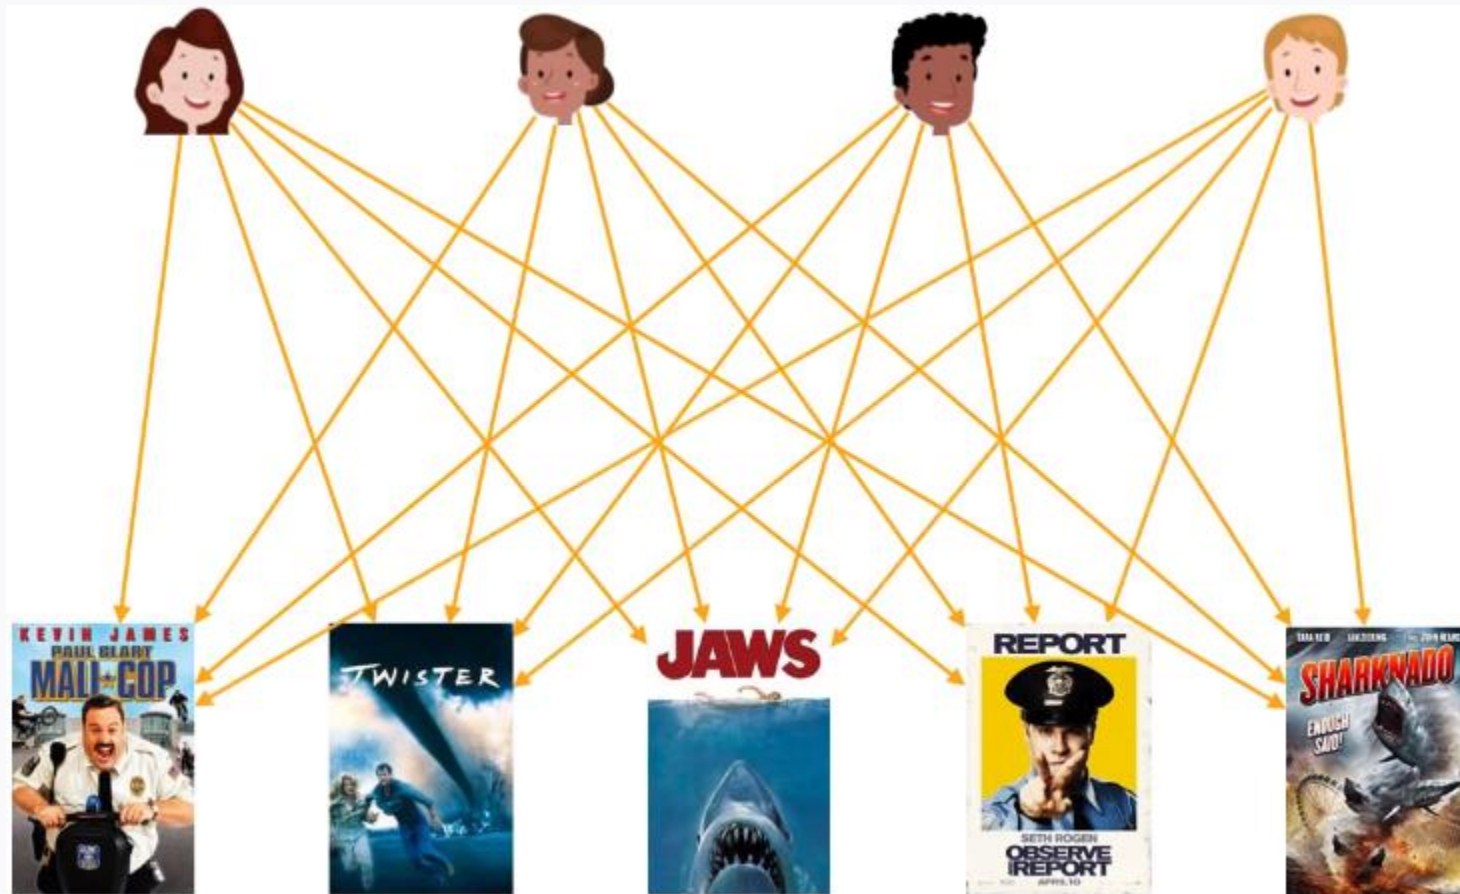


# Как применить SVD для рекомендации фильмов



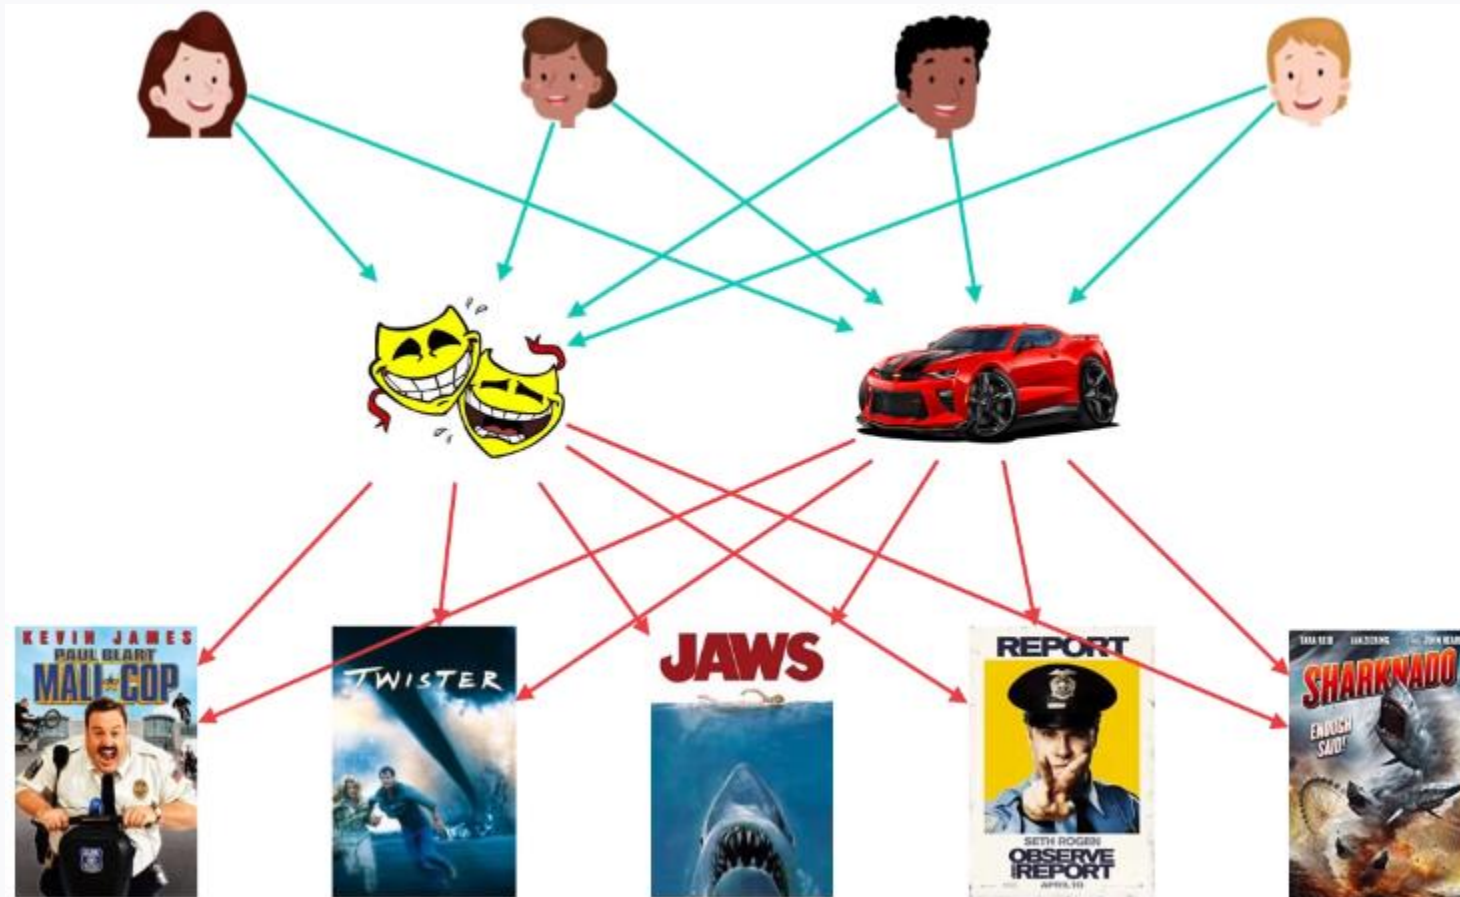


# Как применить SVD для рекомендации фильмов



$$5 \times 4 = 20$$



# Как применить SVD для рекомендации фильмов










$$8 + 10 = 18$$

# Как применить SVD для рекомендации фильмов

Степень присутствия двух признаков в пространствах пользователей и фильмов

	M1	M2	M3	M4	M5
 Comedy	3	1	1	3	1
 Action	1	2	4	1	3

	 Comedy	 Action
 A		
 B		
 C		
 D		


	M1	M2	M3	M4	M5
	3	1	1	3	1
	1	2	4	1	3
	3	1	1	3	1
	4	3	5	4	4



# Как применить SVD для рекомендации фильмов

Что, если некоторых оценок нет и мы хотим их спрогнозировать?

**Вопрос:** как применить SVD?

	M1	M2	M3	M4	M5
	3	1	1	3	1
	1	2	4	1	3
	3	1	1	3	
	4	3	5	4	4


# Alternative Least Squares (ALS)

Попытаемся приблизить заданную матрицу  $X$

$$X_{l,d} \approx U_{l,k} \cdot V_{k,d}^T,$$

В качестве меры схожести используем норму Фробениуса по существующим элементам

$$\mathcal{Q} = \sum_{i,j} \left( \langle \hat{\mathbf{u}}_i, \hat{\mathbf{v}}_j \rangle - x_{ij} \right)^2 \rightarrow \min_{\hat{\mathbf{u}}_i, \hat{\mathbf{v}}_j}$$



От  $k$  зависит то, насколько точно мы сможем приблизить исходную матрицу произведением наших матриц

# Alternative Least Squares (ALS)

Будем использовать метод Градиентного Спуска (GD)

$$\hat{\mathbf{u}}_i^{(t+1)} = \hat{\mathbf{u}}_i^{(t)} - \gamma^{(t)} \frac{\partial Q}{\partial \hat{\mathbf{u}}_i}$$

$$\frac{\partial Q}{\partial \hat{\mathbf{u}}_i} = 2 \sum_j \left( \langle \hat{\mathbf{u}}_i, \hat{\mathbf{v}}_j \rangle - x_{ij} \right) \hat{\mathbf{v}}_j = 2 \sum_j \varepsilon_{ij} \hat{\mathbf{v}}_j^{(t)}$$

$$\varepsilon_{ij} = \langle \hat{\mathbf{u}}_i, \hat{\mathbf{v}}_j \rangle - x_{ij} \quad - \text{невязка}$$

$$\begin{aligned} \hat{\mathbf{u}}_i^{(t+1)} &= \hat{\mathbf{u}}_i^{(t)} - \gamma_u^{(t)} \sum_j \varepsilon_{ij} \hat{\mathbf{v}}_j^{(t)} \\ \hat{\mathbf{v}}_j^{(t+1)} &= \hat{\mathbf{v}}_j^{(t)} - \gamma_v^{(t)} \sum_i \varepsilon_{ij} \hat{\mathbf{u}}_i^{(t)} \end{aligned}$$



# Alternative Least Squares (ALS)

Так как в задаче могут использоваться большие матрицы с произвольной структурой, возможны проблемы со сходимостью.

Используем метод Стохастического Градиентного Спуска (SGD)

$$\begin{aligned}\hat{\mathbf{u}}_i^{(t+1)} &= \hat{\mathbf{u}}_i^{(t)} - \gamma_u^{(t)} \varepsilon_{ij} \hat{\mathbf{v}}_j^{(t)} \\ \hat{\mathbf{v}}_j^{(t+1)} &= \hat{\mathbf{v}}_j^{(t)} - \gamma_v^{(t)} \varepsilon_{ij} \hat{\mathbf{u}}_i^{(t)}\end{aligned}$$

$i, j$  выбираются случайным образом

# Alternative Least Squares (ALS)

Так как в задаче могут использоваться большие матрицы с произвольной структурой, возможны проблемы со сходимостью.

Используем метод Стохастического Градиентного Спуска (SGD)

$$\begin{aligned}\hat{\mathbf{u}}_i^{(t+1)} &= \hat{\mathbf{u}}_i^{(t)} - \gamma_u^{(t)} \boldsymbol{\varepsilon}_{ij} \hat{\mathbf{v}}_j^{(t)} \\ \hat{\mathbf{v}}_j^{(t+1)} &= \hat{\mathbf{v}}_j^{(t)} - \gamma_v^{(t)} \boldsymbol{\varepsilon}_{ij} \hat{\mathbf{u}}_i^{(t)}\end{aligned}$$

$i, j$  выбираются случайным образом

Какие проблемы существуют при использовании этого метода?  
Как выбрать шаг?

# Alternative Least Squares (ALS)

Выведем Альтернативный Метод Наименьших Квадратов

$$\frac{\partial Q}{\partial \hat{\mathbf{u}}_i} = 2 \sum_j \left( \langle \hat{\mathbf{u}}_i, \hat{\mathbf{v}}_j \rangle - x_{ij} \right) \hat{\mathbf{v}}_j = 0$$

$$\sum_j \langle \hat{\mathbf{u}}_i, \hat{\mathbf{v}}_j \rangle \hat{\mathbf{v}}_j = \sum_j x_{ij} \hat{\mathbf{v}}_j$$

Это уже система  
линейных уравнений

$$\begin{cases} \left( \sum_j \hat{\mathbf{v}}_j \hat{\mathbf{v}}_j^T \right) \hat{\mathbf{u}}_i = \sum_j x_{ij} \hat{\mathbf{v}}_j & \Rightarrow \hat{\mathbf{u}}_i \\ \left( \sum_i \hat{\mathbf{u}}_i \hat{\mathbf{u}}_i^T \right) \hat{\mathbf{v}}_j = \sum_i x_{ij} \hat{\mathbf{u}}_i & \Rightarrow \hat{\mathbf{v}}_j \end{cases}$$

$i, j$  выбираются  
случайным образом  
до тех пор, пока не  
сойдется с нужной  
точностью



# Alternative Least Squares (ALS)

Добавим L2 регуляризацию к функционалу для предотвращения переобучения, так как задача может иметь множество решений

$$\mathcal{Q} = \sum_{i,j} \left( \langle \hat{\mathbf{u}}_i, \hat{\mathbf{v}}_j \rangle - x_{ij} \right)^2 + \alpha \sum_i \|\hat{\mathbf{u}}_i\|^2 + \beta \sum_j \|\hat{\mathbf{v}}_j\|^2 \rightarrow \min_{\hat{\mathbf{u}}_i, \hat{\mathbf{v}}_j}$$

$\alpha, \beta$  малые – 0.1, 0.01, и т.д.





LIVE





# SVD в Python

- Максимально просто сделать лишь разложение SVD
- Не так просто осмыслить результат

## Код Python

```
import numpy as np
U, S, V = np.linalg.svd(X)           # Получили сразу три матрицы разложения
```



# Слайд с заданием

- 1 Как выглядит SVD
- 2 SVD в рекомендательных системах
- 3 SVD в сжатии изображений



Тайминг: 30 минут



# Слайд с тезисами

**1** SVD дает произведение двух ортогональных матриц собственных векторов и диагональной матрицы сингулярных чисел

**2** SVD применим в выделении признаков, в снижении размерностей данных, в сжатии, в PCA

**3** Сингулярные числа отсортированы по убыванию. Наибольшее значение имеют первые числа

**4** SVD применимо только к полным матрицам. В случае пропусков применяем ALS

**5** Чистое SVD – это линейное и не всесильное разложение. И часто не самое быстрое.



# Рефлексия



С какими основными мыслями и инсайтами уходите с вебинара?



Достигли ли вы цели вебинара?



# Следующий вебинар

**Тема:** «Матричные производные»



19 июня



Ссылка на вебинар будет в ЛК за 15 минут



Материалы к занятию  
в ЛК — можно  
изучать




Обязательный  
материал обозначен  
красной лентой

# Список материалов для изучения

- Очень много инфы по SVD и регрессии на русском: <http://www.machinelearning.ru/wiki/images/b/b9/Strijov08ln.pdf>
- Дипломная по рекомендациям: [http://www.machinelearning.ru/wiki/images/9/93/2014\\_517\\_RomovPA.pdf](http://www.machinelearning.ru/wiki/images/9/93/2014_517_RomovPA.pdf)
- Основы на русском: <https://www.coursera.org/lecture/unsupervised-learning/matrichnyie-razlozhieniia-DUBp9>
- Мега курс от Стива Брантона!!!: <https://www.youtube.com/playlist?list=PLMrJAKhleNNSVjnsvglFoY2nXildDCcv>
- Как связать SVD и рекомендации фильмов: <https://www.youtube.com/watch?v=ZspR5PZemcs>
- Крутой ресурс «Связь с Методом Главных Компонент»: [https://medium.com/@jonathan\\_hui/machine-learning-singular-value-decomposition-svd-principal-component-analysis-pca-1d45e885e491](https://medium.com/@jonathan_hui/machine-learning-singular-value-decomposition-svd-principal-component-analysis-pca-1d45e885e491)
- Видос: <https://www.youtube.com/watch?v=FgGjc5oabrA>
- Хорошая статейка «Collaborative Filtering for Implicit Feedback Datasets»:  
<http://citeseerx.ist.psu.edu/viewdoc/download;jsessionid=34AEEE06F0C2428083376C26C71D7CFF?doi=10.1.1.167.5120&rep=rep1&type=pdf>






The background of the entire image is an aerial photograph of a city, likely New York City, showing numerous skyscrapers and buildings. The image is overlaid with a semi-transparent blue layer. In the center of this blue layer, there is a white network pattern consisting of dots connected by thin lines, resembling a molecular or digital structure. The text is centered within this blue area.

Заполните, пожалуйста,  
опрос о занятии по ссылке в чате



The background of the entire slide is an aerial photograph of a dense city skyline, likely New York City, with numerous skyscrapers. A semi-transparent blue overlay covers the image, featuring a network of white lines connecting various points, creating a digital or technological aesthetic. The text is centered in the middle of the slide.

Спасибо за внимание!  
Приходите на следующие вебинары

Легкоступ Виктор Валерьевич